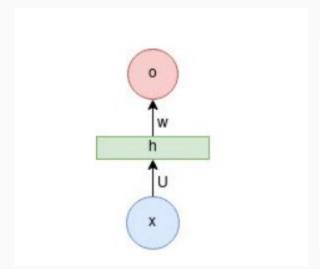
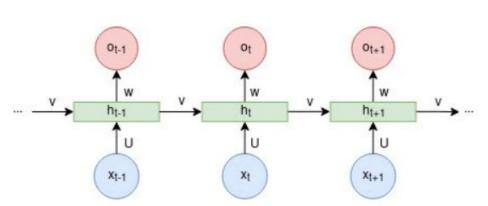
Elmo



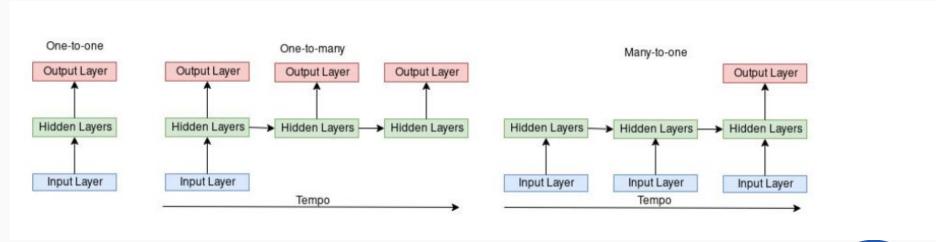
RNN:

-Redes com memoria

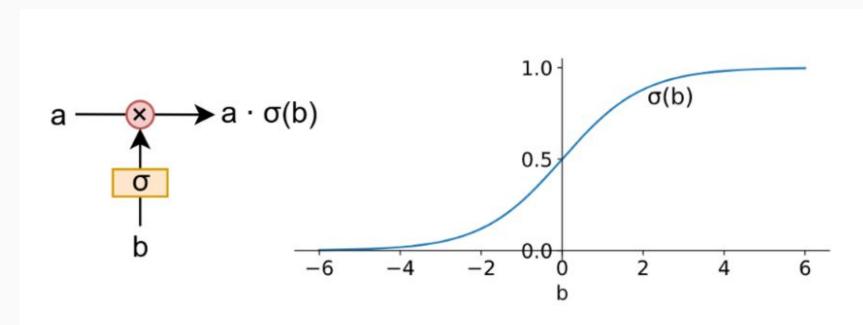




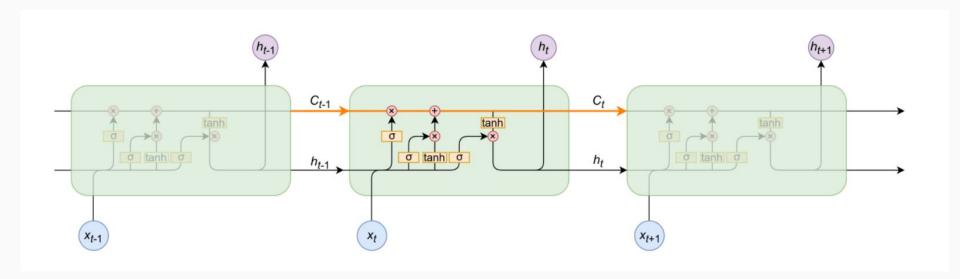










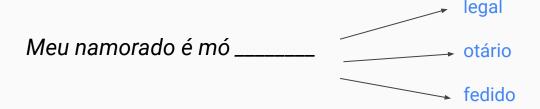




Modelo de Língua

O que é um modelo de língua?

Um modelo de língua procura tentar prever qual é a próxima palavra em uma frase



Uma definição um pouco mais formal ...

Dada uma sequência de palavras x(1), x(2), ..., x(t), qual é a distribuição de probabilidade da próxima palavra x(t+1)?

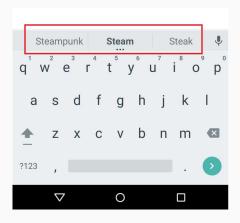
$$P(x(t+1) | x(t), ..., x(1))$$



Modelo de Língua

Isso é o que chamamos de um modelo de língua!

Você também pode pensar nisso como um sistema que atribui uma probabilidade para uma porção de texto







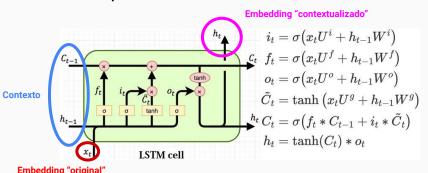
Elmo - introduzindo

"Unlike most widely used word embeddings ELMo word representations are functions of the **entire input** sentence"

ELMo = acrônimo de Embeddings from Language Models

- Parando para pensar, o output de um modelo de língua em RNN/LSTM para uma certa palavra te dá um "embedding" para aquela palavra naquele contexto
 - Já que é feita uma operação matemática englobando tanto um embedding original como um vetor que codifica o contexto

 Essa informação contextual é muito útil para captar variações semânticas de uma mesma palavra



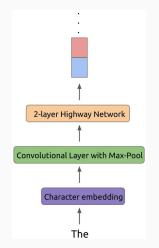


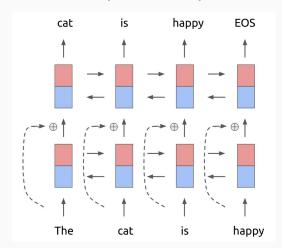


Elmo - arquitetura

"ELMo representations are **deep**, in the sense that they are a function of all of the internal layers of the biLM."

- Um modelo de língua bidirecional
 - Duas LSTMs de dois layers (um em cima do outro) independentes, uma prevendo a palavra seguinte dadas as palavras anteriores. A outra, prevendo a palavra anterior dadas as seguintes
- Embeddings "iniciais" um pouco mais complexos do que o usual

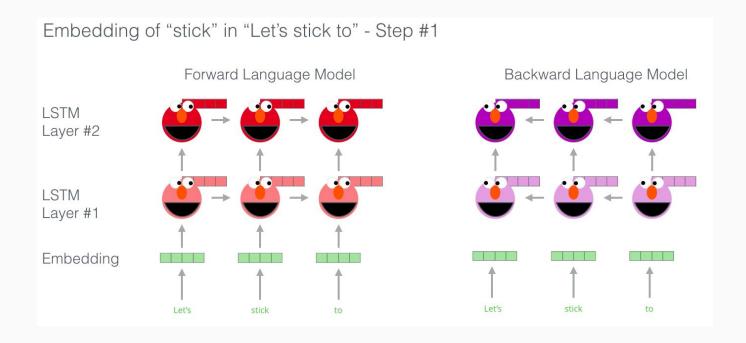






Elmo - arquitetura

"ELMo representations are **deep**, in the sense that they are a function of all of the internal layers of the biLM."





Elmo - o embedding final

"ELMo is a task specific combination of the intermediate layer representations in the biLM"

- Dependendo da tarefa, pode ser mais útil utilizar o output da LSTM de baixo ou de cima
 - Layer de baixo mais "sintático" POS, Parsing
 - Layer de cima mais "semântico"

$$\begin{array}{ll} R_k & = & \{\mathbf{x}_k^{LM}, \overrightarrow{\mathbf{h}}_{k,j}^{LM}, \overleftarrow{\mathbf{h}}_{k,j}^{LM} \mid j=1,\ldots,L\} \\ & = & \{\mathbf{h}_{k,j}^{LM} \mid j=0,\ldots,L\}, \end{array}$$

$$\mathbf{ELMo}_k^{task} = E(R_k; \Theta^{task}) = \gamma^{task} \sum_{j=0}^L s_j^{task} \mathbf{h}_{k,j}^{LM}$$

